

머신러닝 기초

모델 평가의 핵심 개념 — 왜 정확도만으로는 안 되는가

교육용 강의 노트

1. 모델링과 피팅(Fitting).....	2
1-1. 과소적합 · 적정적합 · 과대적합	2
2. 파라미터 vs 하이퍼파라미터.....	3
3. 혼동행렬(Confusion Matrix) 해석	4
4. 평가지표 — 정확도, 재현율, F1, AUC	5
4-1. [중요] 왜 정확도(Accuracy)는 중요하지 않은가?	5
4-2. F1 과 AUC 를 언제 쓰나.....	6
5. 위양성 줄이기 — 1 종 오류와 2 종 오류.....	7
5-1. 위양성(허경보)을 줄이는 실무 방법	7
부록. 한 장 요약.....	9

1. 모델링과 피팅(Fitting)

머신러닝에서 모델링(Modeling)은 데이터 속에 숨은 규칙을 수학적 함수로 표현하는 작업이고, 피팅(Fitting, 학습/적합)은 그 함수의 내부 값들을 데이터에 맞게 조정해 가는 과정이다. 즉 "빈 틀(모델)"을 준비하고, 데이터를 보여주며 "틀을 데이터에 맞춰 깎는" 것이 피팅이다.

- 입력(X) → 모델 $f(X)$ → 예측($\hat{y}$)의 구조에서, 예측이 정답(y)에 가까워지도록 내부 값을 갱신한다.
- 이때 "얼마나 틀렸는가"를 재는 자가 손실 함수(Loss)이고, 손실을 줄이는 방향으로 값을 미는 것이 학습이다.

1-1. 과소적합 · 적정적합 · 과대적합

피팅의 결과는 세 가지로 갈린다. 핵심은 "학습 데이터"가 아니라 "처음 보는 데이터"에서의 성능이다.

- 과소적합(Underfitting): 모델이 너무 단순해 규칙조차 못 배운 상태. 학습·검증 성능이 모두 낮다.
- 적정적합(Good fit): 규칙은 잡고 잡음(noise)은 무시. 검증 데이터에서도 잘 맞는 이상적 상태.
- 과대적합(Overfitting): 학습 데이터를 통째로 외워버림. 학습 성능은 거의 100%인데 새 데이터에선 급락한다.

핵심 직관 — 편향-분산 트레이드오프

- 편향(Bias)이 크면 = 과소적합: 너무 뭉뚱그려 본다.
- 분산(Variance)이 크면 = 과대적합: 잡음까지 따라가 흔들린다.
- 좋은 모델은 둘 사이의 균형점. 그래서 "학습 점수"가 아니라 "검증 점수"로 멈출 시점을 정한다.

2. 파라미터 vs 하이퍼파라미터

이름은 비슷하지만 "누가 정하느냐"가 완전히 다르다. 이 구분이 학습 과정 전체의 뼈대다.

	파라미터 (Parameter)	하이퍼파라미터 (Hyperparameter)
누가 정하나	모델이 학습으로 스스로 찾음	사람이 학습 전에 미리 설정
언제 정해지나	학습(피팅) 도중 갱신	학습 시작 전 고정
예시	회귀계수(가중치 w), 절편 b , 신경망 weight	학습률, 에폭 수, 트리 깊이, K 값, 규제 강도
비유	요리 중 손이 익혀 잡는 "간"	요리 전에 맞춰두는 "오븐 온도·시간"

하이퍼파라미터 튜닝이란 이 "사람이 정하는 값"들의 좋은 조합을 찾는 일이다. 그리드 서치, 랜덤 서치, 베이지안 최적화 등이 쓰이며, 반드시 검증(validation) 데이터로 평가해야 한다. 테스트 데이터로 튜닝하면 점수를 속이게 된다.

3. 혼동행렬(Confusion Matrix) 해석

모든 분류 평가지표는 결국 이 2×2 표 한 장에서 나온다. 여기를 못 읽으면 정확도·정밀도·재현율을 외워도 무용지물이다.

	예측: 양성(P)	예측: 음성(N)
실제: 양성(P)	TP True Positive 맞게 잡은 양성	FN False Negative 놓친 양성 · 2 종 오류
실제: 음성(N)	FP False Positive 헛경보 · 1 종 오류	TN True Negative 맞게 거른 음성

읽는 법은 항상 "뒤 글자(P/N) = 모델의 예측, 앞 글자(T/F) = 그 예측이 맞았는가"이다.

- **TP** : 양성이라 했고 실제로 양성 — 정답
- **TN** : 음성이라 했고 실제로 음성 — 정답
- **FP** : 양성이라 했는데 사실은 음성 — 위양성 / 1 종 오류(헛경보)
- **FN** : 음성이라 했는데 사실은 양성 — 위음성 / 2 종 오류(놓침)

외우는 한 줄

"F 로 시작하면 틀린 것, 뒤 글자는 모델이 뭐라고 했는지."

FP = 모델이 'P(양성)'라고 했는데 틀림(헛경보), FN = 모델이 'N(음성)'이라 했는데 틀림(놓침).

4. 평가지표 — 정확도, 재현율, F1, AUC

혼동행렬의 네 칸(TP·FP·FN·TN)을 어떻게 조합하느냐에 따라 보는 관점이 달라진다.

지표	계산식	질문 / 무엇을 보는가
정확도 Accuracy	$(TP+TN) / \text{전체}$	전체 중 맞춘 비율. 클래스가 한쪽으로 쏠리면 의미가 무너진다.
정밀도 Precision	$TP / (TP+FP)$	"양성이라 한 것 중 진짜 양성?" 위양성(FP)이 비쌀 때 중요.
재현율 Recall(민감도)	$TP / (TP+FN)$	"실제 양성 중 몇 개를 잡았나?" 놓침(FN)이 치명적일 때 중요.
F1 점수	$2 \cdot (P \cdot R) / (P+R)$	정밀도와 재현율의 조화평균. 둘의 균형을 한 숫자로.
AUC (ROC 곡선 아래 면적)	ROC 곡선 적분 (0.5~1.0)	임계값을 옮겨가며 본 종합 분별력. 0.5=무작위, 1.0=완벽.

4-1. [중요] 왜 정확도(Accuracy)는 중요하지 않은가?

정확도는 가장 먼저 배우지만, 실무에서 가장 사람을 속이는 지표다. 이유는 한 단어로 "불균형(imbalance)"이다.

암 진단 데이터에서 실제 환자가 **100 명 중 1 명(1%)**이라고 하자. 아무 학습도 하지 않고 무조건 "정상"이라고만 답하는 바보 모델을 만들면, 100 명 중 99 명을 맞히므로 정확도는 **무려 99%**가 나온다. 숫자는 화려하지만, 정작 잡아야 할 환자는 단 한 명도 못 잡았다.

지표	바보 모델 ("전부 정상"이라 답)	쓸모 있는 모델
정확도(Accuracy)	99.0% (높아 보임!)	98.2%
재현율(Recall, 환자 검출)	0% (한 명도 못 잡음)	90%
정밀도(Precision)	정의 불가 (양성 예측 0)	85%

이 표가 말하는 바는 분명하다. 정확도 99%짜리 모델이 정확도 98%짜리 모델보다 훨씬 위험하다. 정확도는 "다수 클래스를 잘 맞혔는지"에 끌려다니기 때문에, 정작 중요한 소수 클래스(환자, 사기, 불량) 성능을 가려버린다.

그래서 무엇을 봐야 하나

- 데이터가 불균형하면 정확도 대신 정밀도·재현율·F1 을 본다.
- 놓치면 큰일(암, 사기, 화재) → 재현율(Recall)을 우선한다.
- 헛경보가 비싸면(스팸으로 중요 메일 삭제, 멀쩡한 거래 차단) → 정밀도(Precision)를 우선한다.
- 둘의 균형을 한 숫자로 보고 싶으면 F1, 임계값과 무관한 종합 분별력을 보려면 AUC.

4-2. F1 과 AUC 를 언제 쓰나

- **F1 점수** : 정밀도와 재현율이 서로 줄다리기를 할 때, 한쪽만 높고 다른 쪽이 낮은 모델에 벌점을 준다(조화평균이라 낮은 쪽에 끌려감). 불균형 데이터의 단일 비교 지표로 적합.
- **AUC(ROC)** : 분류 임계값(0.5 등)을 0 부터 1 까지 전부 옮겨보며 그린 곡선의 면적. 임계값을 어디에 두든 "양성을 음성보다 앞에 세우는 능력"을 하나로 요약한다. 0.5 는 동전 던지기, 1.0 은 완벽.

5. 위양성 줄이기 — 1 종 오류와 2 종 오류

통계의 가설검정 용어가 그대로 머신러닝으로 넘어온 것이다. 두 오류는 본질적으로 "트레이드오프" 관계라, 동시에 0으로 만들 수는 없다.

구분	정체	의미	현실 예시(스팸 필터)
1 종 오류 (Type I)	위양성 (FP) 거짓 정보	아닌데 맞다고 함 (귀무가설을 잘못 기각)	정상 메일을 스팸으로 분류 → 중요한 메일을 놓침
2 종 오류 (Type II)	위음성 (FN) 놓침	맞는데 아니라고 함 (거짓 귀무가설을 못 기각)	스팸을 정상으로 통과 → 받은편지함이 더러워짐

핵심 — 둘은 시소다

임계값(threshold)을 올려 "확실할 때만 양성"이라 하면 → 위양성(FP) ↓ 정밀도 ↑, 하지만 놓침(FN) ↑ 재현율 ↓.

임계값을 내려 "의심되면 일단 양성"이라 하면 → 놓침(FN) ↓ 재현율 ↑, 하지만 위양성(FP) ↑ 정밀도 ↓.

그래서 "무엇을 더 두려워하는가"를 먼저 정하고 임계값을 옮긴다.

5-1. 위양성(헛경보)을 줄이는 실무 방법

1. 분류 임계값을 높인다 : 0.5 → 0.7 등으로 올려, 모델이 충분히 확신할 때만 양성 판정. 가장 직접적이고 즉시 효과가 있다.
2. 정밀도(Precision)를 최적화 지표로 삼는다 : 모델 선택·튜닝 기준을 정확도가 아니라 정밀도(또는 Precision 중심 F-beta)로 둔다.
3. 특징·데이터 품질을 개선한다 : 양성·음성을 가르는 변별력 있는 변수를 추가하고, 라벨 오류를 정리한다.
4. 비용 민감 학습 / 클래스 가중치 : FP 에 더 큰 페널티를 부여해 모델이 함부로 양성이라 하지 않도록 학습시킨다.

5. **PR 곡선으로 운영점을 고른다** : Precision-Recall 곡선에서 허용 가능한 재현율을 유지하는 선에서 정밀도가 가장 높은 임계값을 채택한다.

단, 공짜는 없다

위양성을 줄이려고 임계값을 높이면 거의 항상 위음성(놓침)이 늘어난다.

암 진단·사기탐지처럼 "놓치면 더 큰 손해"인 영역에서는 위양성을 일부 감수하고 재현율을 지키는 편이 옳다.

결국 정답은 도메인이 정한다 — 지표는 의사결정을 돕는 도구일 뿐, 목표 그 자체가 아니다.

부록. 한 장 요약

- 피팅 = 모델을 데이터에 맞춰 깎기. 핵심은 학습 점수가 아니라 검증 점수(과대적합 경계).
- 파라미터 = 모델이 학습으로 찾는 값 / 하이퍼파라미터 = 사람이 미리 정하는 값.
- 모든 분류 지표는 혼동행렬(TP·FP·FN·TN)에서 나온다.
- 정확도는 불균형 데이터에서 사람을 속인다 — 소수 클래스가 중요하다면 재현율·정밀도·F1·AUC 를 본다.
- 1 종 오류 = 위양성(헛경보) / 2 종 오류 = 위음성(놓침), 둘은 시소 관계.
- 위양성을 줄려면 임계값 ↑ ·정밀도 최적화·비용가중·PR 곡선 활용 — 단 놓침(FN) 증가를 각오할 것.